

Trabajo de Fin de Grado

Detección de fraude con GNNs frente a métodos tradicionales de machine learning

Fraud detection with GNNs versus
traditional machine learning methods

Samuel Frías Hernández

La Laguna, Día de Mes de 2026

D. **Marcos Colebrook Santamaría**, con N.I.F. 43.787.808-V, profesor Titular de Universidad adscrito al Departamento de Ingeniería Informática y de Sistemas de la Universidad de La Laguna, como tutor.

C E R T I F I C A

Que la presente memoria titulada:

«Detección de fraude con GNNs frente a métodos tradicionales de machine learning»

ha sido realizada bajo su dirección por D. **Samuel Frías Hernández**, con N.I.F. 79.356.066-V.

Y para que así conste, en cumplimiento de la legislación vigente y a los efectos oportunos firman la presente en La Laguna a Día de Mes de 2026.

Agradecimientos

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Licencia



This work is licensed under CC BY-NC-SA 4.0.

Resumen

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Palabras clave: Palabra1, Palabra2, Palabra3.

Abstract

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Keywords: Keyword1, Keyword2, Keyword3.

Índice general

1. Introducción	1
2. Antecedentes	3
2.1. Evolución desde el <i>Machine Learning</i> Tradicional	3
2.2. Adopción de <i>Graph Neural Networks</i>	3
2.3. Desafíos Actuales	4
2.4. Datasets y la Necesidad de Explicabilidad	4
3. Desarrollo	5
3.1. Selección del Conjunto de Datos	5
3.1.1. Limitaciones Algorítmicas de los Modelos	5
3.1.2. Criterios Rigurosos para la Selección	6
3.1.3. Resolución Final	8
4. Resultados	9
5. Conclusiones	10
6. Summary	11
7. Presupuesto	12
Bibliografía	13

Índice de figuras

Índice de cuadros

Capítulo 1

Introducción

La detección automática de fraude financiero es un desafío analítico y computacional crítico en la minería de datos, la ciberseguridad y el aprendizaje automático. El panorama de las transacciones financieras ha incrementado su complejidad de manera exponencial durante la última década, impulsado por la integración económica global, la adopción masiva de pasarelas de pago digitales, y los continuos avances en las tecnologías de la información [1].

Esta hiperconectividad, aunque favorece el comercio legítimo, amplía significativamente la superficie de ataque, propiciando esquemas fraudulentos más sofisticados y difíciles de rastrear mediante heurísticas convencionales. A nivel macroeconómico, se estima que las pérdidas mundiales por fraude con tarjetas de crédito alcanzarán los 403.88 mil millones de dólares durante la próxima década [2].

En un espectro delictivo aún más amplio, la Oficina de las Naciones Unidas contra la Droga y el Delito estima que el blanqueo de capitales, una tipología de fraude que involucra el movimiento de fondos ilícitos para ocultar sus orígenes, representa entre el 2 % y el 5 % del Producto Interior Bruto (PIB) mundial, lo que se traduce en un volumen de lavado que oscila entre los 0.8 y 2.0 billones de dólares anuales [3].

Frente a esta amenaza sistémica, la industria financiera y la comunidad académica han dependido históricamente de enfoques estadísticos y de aprendizaje automático tradicional (*Machine Learning*), tales como la Regresión Logística, las Máquinas de Vectores de Soporte (*SVM*), los Árboles de Decisión, y los potentes métodos por conjuntos como *Random Forest* y *Gradient Boosting* (por ejemplo, *XGBoost* o *LightGBM*). Estos sistemas han demostrado ser eficaces hasta cierto punto, ofreciendo capacidades predictivas robustas cuando se enfrentan a patrones de fraude aislados o comportamientos atípicos evidentes en una única transacción [4].

Sin embargo, la naturaleza misma del fraude financiero moderno ha evolucionado desde incidentes simples e inconexos hacia redes delictivas altamente organizadas e interconectadas. Los defraudadores profesionales operan mediante redes de mulas de dinero, la reutilización coordinada de dispositivos móviles comprometidos, la creación de identidades sintéticas, y esquemas de estratificación de blanqueo de capitales que involucran cadenas complejas de transferencias diseñadas matemáticamente para ofuscar el origen de los fondos ilícitos [5].

La limitación fundamental de los modelos clásicos de aprendizaje automático reside en su ceguera topológica. Estos algoritmos están diseñados para operar sobre datos tabulares, donde cada fila (una transacción) se trata como un vector de características independiente en un espacio euclidiano [2]. Al analizar un evento de forma aislada, un modelo como *XGBoost* puede determinar que una transferencia de cincuenta dólares desde una dirección IP residencial no viola ninguna regla de negocio estática ni presenta anomalías estadísticas en su importe [6]. El modelo tabular no captura la red de relaciones subyacentes, como el hecho de que una misma dirección IP haya sido compartida por cincuenta cuentas de usuario distintas en las últimas dos horas para transferir cantidades idénticas a una cuenta centralizadora [5].

Para superar esta limitación, las Redes Neuronales Gráficas (*Graph Neural Networks* o *GNNs*) se han consolidado como un enfoque destacado en la literatura científica reciente sobre detección de anomalías [1]. Las *GNNs* poseen la capacidad única e inherente de aprender representaciones vectoriales densas (*embeddings*) a partir de datos estructurados en forma de redes no euclidianas. Modifican el enfoque predictivo al modelar de manera explícita y matemática las interacciones complejas entre nodos (entidades como usuarios, tarjetas de crédito, comercios o dispositivos) y aristas (relaciones dinámicas como transacciones, accesos compartidos o transferencias de capital). A través de un proceso iterativo conocido como paso de mensajes (*message passing*) o convolución de grafos, las *GNNs* permiten que la evaluación del riesgo de una transacción específica esté informada contextualmente por el comportamiento histórico y la topología de todas las entidades vecinas en el grafo, extendiéndose a múltiples «saltos» (*hops*) de distancia [4].

Capítulo 2

Antecedentes

La detección de fraude financiero ha experimentado una evolución significativa en la última década, impulsada por la creciente sofisticación de los ataques y el volumen masivo de transacciones digitales. Históricamente, las instituciones financieras han dependido de sistemas basados en reglas y algoritmos de *Machine Learning* tradicional. Sin embargo, la literatura reciente refleja una transición clara hacia los modelos basados en el aprendizaje profundo de grafos (*GNNs*) para abordar las limitaciones de los enfoques convencionales.

2.1. Evolución desde el *Machine Learning* Tradicional

Los métodos tradicionales de aprendizaje automático supervisado han sido el estándar en la industria durante años debido a su alta precisión tabular [7]. Recientemente, autores como Almalki y Masud han demostrado que el uso de ensamblajes apilados (*stacking ensembles*) combinando *XGBoost*, *LightGBM* y *CatBoost* sigue ofreciendo resultados competitivos en la detección de anomalías crediticias [8].

No obstante, estos modelos tabulares presentan una limitación estructural fundamental: asumen que las transacciones son eventos independientes. Al aplanar los datos para su procesamiento, ignoran la rica información topológica y las relaciones subyacentes entre las entidades involucradas (usuarios, cuentas, dispositivos, etc.), lo cual es crucial dado que los defraudadores modernos operan en redes coordinadas y complejas [1].

2.2. Adopción de *Graph Neural Networks*

Para superar la falta de contexto relacional, la comunidad científica ha volcado sus esfuerzos en las *Graph Neural Networks*. Las *GNNs* han demostrado una capacidad excepcional para capturar patrones relacionales y dinámicas dentro de redes financieras, superando significativamente a los modelos no relacionales en diversas métricas de evaluación [1].

Estudios comparativos directos respaldan esta transición. Por ejemplo, Lu propuso un modelo integral que combina Redes Convolucionales de Grafos (*GCN*) y Redes de Atención de Grafos (*GAT*) para la agregación jerárquica de características, demostrando sobre conjuntos de datos públicos (como el IEEE-CIS) que las *GNNs* superan con creces a la Regresión Logística, *SVM* y *Random Forest* en términos de precisión y *F1-Score* [7]. Este

tipo de evidencias fundamentan la necesidad de evaluar y comparar sistemáticamente ambas familias de algoritmos en entornos controlados.

2.3. Desafíos Actuales

A pesar de su éxito, la aplicación de *GNNs* en la detección de fraude se enfrenta a desafíos intrínsecos del dominio financiero que la literatura actual intenta mitigar:

- **Naturaleza tabular de los datos originales:** gran parte de los datos financieros se recopilan en formato tabular, no como grafos explícitos. Investigaciones recientes abordan este problema mediante módulos de aprendizaje métrico que optimizan la construcción del grafo a partir de datos tabulares, asegurando que se cumplan las suposiciones de homofilia (nodos similares tienden a conectarse) necesarias para que las *GNNs* funcionen correctamente [9].
- **Desbalanceo extremo de clases:** las transacciones fraudulentas representan una fracción minúscula frente a las legítimas. Para evitar que las *GNNs* se sesguen hacia la clase mayoritaria, se están explorando técnicas de muestreo híbrido y aprendizaje adversarial adaptativo, que generan transacciones sintéticas fraudulentas en regiones densas del espacio de características y eliminan ruido, equilibrando así el entrenamiento [9].
- **Detección en tiempo real y dinamismo:** el fraude ocurre de manera instantánea, por lo que los modelos deben inferir de forma rápida y adaptarse a redes que cambian temporalmente. Sultana et al. presentaron el modelo *detectGNN*, el cual incorpora patrones basados en el tiempo y actualizaciones dinámicas del grafo para exponer fraudes multicapa de manera escalable [4]. En la misma línea, enfoques híbridos han combinado *GNNs* con *autoencoders* [10] o con técnicas de detección de anomalías no supervisadas [6] para procesar arquitecturas de transmisión de datos en tiempo real, mejorando la prevención inmediata del fraude con tarjetas de crédito.

2.4. Datasets y la Necesidad de Explicabilidad

El avance en este campo se ha visto tradicionalmente obstaculizado por la confidencialidad de los datos bancarios. Aunque existen conjuntos públicos de referencia, la comunidad demanda escenarios más realistas. Ante esto, investigaciones de IBM han desarrollado simuladores para generar transacciones financieras sintéticas realistas orientadas a modelos de prevención de blanqueo de capitales (*Anti Money Laundering*), proporcionando *benchmarks* estandarizados sin comprometer la privacidad [3].

Finalmente, un aspecto crítico para la adopción real de estos modelos en la industria es la transparencia. Las normativas financieras exigen que las decisiones algorítmicas sean interpretables, lo que choca con la naturaleza de «caja negra» del aprendizaje profundo. Mientras que para los modelos tradicionales y de ensamblaje ya se aplican con éxito técnicas de Inteligencia Artificial Explicable (*XAI*) como *SHAP* (*SHapley Additive exPlanations*) o *LIME* [8], la explicabilidad aplicada específicamente a predicciones sobre grafos y *GNNs* sigue siendo un campo emergente y con un alto potencial de investigación. La capacidad no solo de predecir el fraude, sino de identificar qué subgrafo o conexiones exactas motivaron la alarma, representa la frontera actual en la investigación de este campo.

Capítulo 3

Desarrollo

3.1. Selección del Conjunto de Datos

La selección del conjunto de datos es un paso fundamental para comparar la eficacia de las *GNNs* frente a los métodos tradicionales. No todos los datos tabulares pueden transformarse de manera efectiva en un grafo, y no todos los grafos contienen la semántica necesaria para permitir una interpretación comprensible de sus resultados. El análisis se guiará por requisitos sumamente específicos: la necesidad de identificadores relacionales claros que permitan la ingeniería topológica desde cero, la representación fiel del desbalanceo de clases inherente al fraude, y, de manera crucial, la interpretabilidad semántica de las variables para satisfacer la implementación de módulos de explicabilidad (*explainable AI* o *XAI*) aplicados a inferencias complejas sobre grafos.

3.1.1. Limitaciones Algorítmicas de los Modelos

Los métodos de aprendizaje automático tradicionales, que han sido el pilar de los sistemas anti-fraude bancarios durante las últimas dos décadas, exigen que la información se estructure en una matriz bidimensional plana. En esta matriz, comúnmente almacenada en formatos como *CSV* o bases de datos relacionales tradicionales, las filas representan las instancias u observaciones (las transacciones individuales) y las columnas representan las características o variables (los atributos de dicha transacción) [10]. Algoritmos como la Regresión Logística, las Máquinas de Vectores de Soporte (*SVM*), los Árboles de Decisión, y los Perceptrones Multicapa (*Multi-Layer Perceptrons* o *MLP*) procesan cada vector fila de manera ortogonal e independiente [7].

La eficacia de estos modelos depende en gran medida de la ingeniería de características (*feature engineering*), una fase de procesamiento manual susceptible a introducir sesgos o errores [6]. Para que un modelo *Random Forest* o *XGBoost* pueda intuir que una transacción forma parte de un ataque coordinado, el investigador debe crear manualmente variables sintéticas temporales y espaciales antes del entrenamiento [11]. Por ejemplo, a partir de un conjunto de datos en bruto, se deben calcular de forma intensiva columnas agregadas como:

- «numero_transacciones_tarjeta_ultimas_24h»,
- «velocidad_gasto_dispositivo_ultimo_mes» o

- «`distancia_geografica_transacciones_consecutivas`».

Si no se anticipa una tipología de fraude emergente y, por tanto, no se genera la variable precalculada correspondiente, el modelo tradicional será completamente ciego ante esa amenaza, independientemente de la profundidad de sus árboles de decisión [6]. Además, estos modelos estadísticos sufren de manera asimétrica ante el problema del desbalanceo de clases; dado que las transacciones fraudulentas a menudo representan menos del 1 % del total en los entornos bancarios reales, los modelos tienden a converger hacia una clasificación mayoritaria constante (prediciendo siempre «no fraude») requiriendo técnicas de sobremuestreo como *SMOTE* o *ADASYN*, que pueden introducir ruido en los datos y elevar la tasa de falsos positivos en entornos de producción [9].

Las Redes Neuronales Gráficas modelan los datos directamente como un grafo $G = (V, E)$, lo que permite procesar la topología y las interconexiones de las transacciones sin necesidad de aplanarlas en una estructura tabular [7].

La innovación fundamental de las *GNNs* es el paradigma de actualización de representaciones basado en la vecindad. En una arquitectura típica de Red Convolutiva de Grafos (*Graph Convolutional Network* o *GCN*), la representación vectorial oculta de un nodo en la capa $k + 1$ se computa agregando (mediante funciones invariantes a la permutación como la suma, la media o el máximo) las representaciones ocultas de todos sus nodos vecinos en la capa k , combinadas con su propia representación anterior, seguido de una transformación lineal y una función de activación no lineal [7].

Este proceso permite que la información sobre el comportamiento sospechoso fluya a través de la red de pagos. Si una cuenta bancaria legítima transfiere dinero accidentalmente a una entidad marcada previamente como fraudulenta (una mula de dinero conocida), la *GNN* propagará esa «señal de riesgo» a través de la arista que las conecta. En las capas subsecuentes, la representación embebida de la cuenta originalmente legítima se ajustará matemáticamente para reflejar su proximidad estructural a un clúster de actividad delictiva, permitiendo una clasificación preventiva antes de que el fraude se materialice por completo [1].

Para ejecutar una comparativa empírica rigurosa entre estos dos mundos analíticos, el conjunto de datos elegido debe, paradójicamente, satisfacer a ambos paradigmas. Debe poseer características tabulares continuas y categóricas ricas para entrenar las líneas base de *XGBoost* y *SVM*, y simultáneamente debe contener el rastro criptográfico relacional explícito para permitir la inferencia de las matrices de adyacencia necesarias para las *GNNs*.

3.1.2. Criterios Rigurosos para la Selección

Tras una revisión exhaustiva de la literatura, se establecen cuatro criterios cardinales innegociables que el *dataset* óptimo debe satisfacer simultáneamente para un análisis que incluya módulos de explicabilidad algorítmica.

1. Existencia de Identificadores Relacionales Unívocos

El *dataset* no requiere presentarse en un formato de grafo precompilado (como archivos de listas de aristas de *NetworkX* o grafos serializados de *PyTorch Geometric*), pero es absolutamente imperativo que los datos tabulares sin procesar incluyan identificadores relacionales persistentes. Estos identificadores son las «claves primarias» y «claves

ajenas» conceptuales que conectan entidades dispares a lo largo del tiempo. Un *dataset* tabular que simplemente liste «Transaccion_ID, Monto, Fecha, Etiqueta_Fraude» es topológicamente estéril e inservible para *GNNs*. El *dataset* debe contener obligatoriamente campos como «Cuenta_Origen», «Cuenta_Destino», «ID_Dispositivo_Cliente», «MAC_Address», «Correo_Electronico» o «Hash_Tarjeta» [5].

Estos identificadores son la materia prima heurística que permitirá, en fases posteriores de la investigación, establecer las conexiones matemáticas que conforman las aristas del grafo. Si el cliente A transfiere al cliente B , y el cliente B transfiere al cliente C , los identificadores unívocos permitirán al algoritmo ensamblar una cadena dirigida $A \rightarrow B \rightarrow C$, revelando una potencial tipología de interacción de lavado de dinero [12].

2. Transparencia Semántica e Interpretabilidad de Atributos

Este es el criterio más restrictivo y el que descalifica a la mayoría de los conjuntos de datos del mundo real publicados por instituciones bancarias. Un objetivo fundamental de la investigación contemporánea es explorar la interpretabilidad mediante técnicas de explicabilidad (*XAI*) aplicadas a *GNNs*. Cuando un banco comercial dona un conjunto de datos a la comunidad científica, lo hace tras un agresivo proceso de ofuscación de datos y Análisis de Componentes Principales (*PCA*) para cumplir estipulaciones de privacidad como el *GDPR* o normativas de la *SEC*. El resultado es un *dataset* donde las columnas se etiquetan como $V_1, V_2, \dots, V_n$, y los valores son proyecciones numéricas continuas sin significado humano [11].

Para un algoritmo *XGBoost* orientado exclusivamente a maximizar el Área Bajo la Curva ROC (*AUC*), esta ofuscación es irrelevante; el álgebra lineal subyacente sigue funcionando. Sin embargo, para un proyecto de investigación que persigue la explicabilidad, es catastrófico. Si una red neuronal gráfica entrenada y sometida a un algoritmo como *GNNExplainer* determina que un nodo fue clasificado como fraudulento porque el nodo vecino tenía un valor anómalo en la característica V_{42} , el hallazgo es semánticamente vacío y carece de aplicabilidad en el mundo real. Por consiguiente, el *dataset* ideal debe preservar la integridad semántica de sus columnas: los montos deben ser monetarios, las fechas deben ser marcos temporales decodificables, y las categorías de comerciantes deben ser comprensibles (ej., «Joyería», «Supermercado», «Criptomonedas») [8]. Solo así el módulo de explicabilidad podrá concluir inferencias analíticas útiles, del tipo: «El modelo predijo un 99 % de riesgo de fraude debido a una estructura en estrella donde un mismo dispositivo móvil intentó compras simultáneas de alto valor en joyerías internacionales» [5].

3. Fiel Representación del Desbalanceo de Clases

La detección de anomalías es fundamentalmente el estudio del desbalanceo extremo. En los sistemas de pagos globales, el fraude es afortunadamente un evento raro, típicamente representando entre el 0.1 % y el 5 % del volumen transaccional total [11]. Un conjunto de datos artificialmente equilibrado (50 % fraude, 50 % legítimo) induciría a un sesgo metodológico masivo, resultando en un modelo que sufriría un colapso de precisión (*precision collapse*) en un entorno de producción, generando miles de falsos positivos y paralizando la experiencia de usuario [2].

El *dataset* seleccionado debe reflejar esta asimetría orgánica. Esta disparidad obliga al marco de evaluación de la investigación a abandonar métricas engañosas como la exactitud

simple (*accuracy*) y adoptar métricas robustas frente al desbalanceo, tales como el Área Bajo la Curva Precisión-Recall (*PR-AUC*), la Puntuación F1 (*F1-Score*), y matrices de confusión detalladas. El desafío para las *GNNs* será demostrar su superioridad sobre *Random Forest* precisamente en estas métricas críticas, localizando la escasez de anomalías en un inmenso mar de nodos lícitos.

4. Accesibilidad, Escala y Formato Abierto

Finalmente, para la ejecución práctica de un Trabajo de Fin de Grado (TFG) o investigación independiente, el conjunto de datos debe ser intrínsecamente público, libre de licencias comerciales restrictivas (como *NDAs* bancarios) y poseer un volumen estadísticamente significativo. Conjuntos de datos con solo mil registros, como *Fraud Guard Synthetic 2025* [13], son excelentes para tutoriales de pregrado y depuración de código, pero carecen de la escala necesaria para que el entrenamiento profundo de una arquitectura *GAT* revele ventajas sobre modelos estadísticos superficiales. Se requiere un *dataset* del orden de cientos de miles o millones de registros tabulares para que la red neuronal tenga suficientes ejemplos para optimizar sus hiperparámetros y converger adecuadamente sin caer en el sobreajuste (*overfitting*) masivo [11].

3.1.3. Resolución Final

Para cumplir con los requisitos de esta investigación, se ha seleccionado el *IBM Transactions for Anti Money Laundering (AML) Dataset*, publicado en *NeurIPS 2023* [3], como el conjunto de datos de referencia.

El *dataset* IBM AML resuelve las limitaciones descritas anteriormente, proporcionando una matriz tabular extensa con un desbalanceo natural de clases y sin variables ofuscadas [14]. Incluye los identificadores relacionales explícitos (banco, origen, receptor, divisa) necesarios para construir el grafo heterogéneo $G(V, E, R)$ durante la fase de preprocesamiento. Esta estructura permite que el módulo de explicabilidad identifique de forma comprensible redes complejas de blanqueo de capitales, una tarea estructuralmente inalcanzable para modelos tabulares basados en árboles como *XGBoost*.

De forma complementaria, se utilizará el *BankSim Dataset* para establecer una línea base estadística. Sus identificadores sintéticos permiten modelar relaciones en grafos y detectar anomalías estructurales que los métodos basados exclusivamente en datos tabulares, como *SVM*, no logran identificar [6].

Capítulo 4

Resultados

Capítulo 5

Conclusiones

Capítulo 6

Summary

Capítulo 7

Presupuesto

Bibliografía

- [1] Dawei Cheng et al. «Graph Neural Networks for Financial Fraud Detection: A Review». En: *Frontiers of Computer Science* 19.9 (sep. de 2025), pág. 199609. ISSN: 2095-2228, 2095-2236. DOI: [10.1007/s11704-024-40474-y](https://doi.org/10.1007/s11704-024-40474-y). URL: <https://link.springer.com/10.1007/s11704-024-40474-y>.
- [2] Naim, Brad Rees y Summer Liu. *Supercharging Fraud Detection in Financial Services with Graph Neural Networks*. NVIDIA Technical Blog. 3 de jun. de 2025. URL: <https://developer.nvidia.com/blog/supercharging-fraud-detection-in-financial-services-with-graph-neural-networks/>.
- [3] Erik Altman et al. *Realistic Synthetic Financial Transactions for Anti-Money Laundering Models*. 2023. DOI: [10.48550/ARXIV.2306.16424](https://doi.org/10.48550/ARXIV.2306.16424). URL: <https://arxiv.org/abs/2306.16424>. Prepublicado.
- [4] Irin Sultana et al. *detectGNN: Harnessing Graph Neural Networks for Enhanced Fraud Detection in Credit Card Transactions*. 2025. DOI: [10.48550/ARXIV.2503.22681](https://doi.org/10.48550/ARXIV.2503.22681). URL: <https://arxiv.org/abs/2503.22681>. Prepublicado.
- [5] *A Graph-Based Approach to Financial Fraud Detection*. Neo4j Graph Data Platform. URL: <https://neo4j.com/developer/industry-use-cases/finserv/retail-banking/ieee-cis-fraud-graphs/>.
- [6] Iftekhar Rasul et al. «Detecting Financial Fraud in Real-Time Transactions Using Graph Neural Networks and Anomaly Detection». En: *Journal of Economics, Finance and Accounting Studies* 6.1 (25 de feb. de 2024), págs. 131-142. ISSN: 2709-0809. DOI: [10.32996/jefas.2024.6.1.13](https://doi.org/10.32996/jefas.2024.6.1.13). URL: <https://al-kindipublisher.com/index.php/jefas/article/view/10159>.
- [7] Sirui Lu. «Graph Neural Network Model in Financial Fraud Detection». En: *2025 2nd International Conference on Intelligent Computing and Robotics (ICICR)*. 2025 2nd International Conference on Intelligent Computing and Robotics (ICICR). Dalian, China: IEEE, 16 de mayo de 2025, págs. 998-1002. ISBN: 979-8-3315-4429-4. DOI: [10.1109/ICICR65456.2025.00176](https://doi.org/10.1109/ICICR65456.2025.00176). URL: <https://ieeexplore.ieee.org/document/11172714/>.
- [8] Fahad Almalki y Mehedi Masud. *Financial Fraud Detection Using Explainable AI and Stacking Ensemble Methods*. Ver. 1. 2025. DOI: [10.48550/ARXIV.2505.10050](https://doi.org/10.48550/ARXIV.2505.10050). URL: <https://arxiv.org/abs/2505.10050>. Prepublicado.
- [9] Lina Ni et al. «HMOA-GNN: Adaptive Adversarial GraphSAGE with Hierarchical Hybrid Sampling and Metric-Optimized Graph Construction for Credit Card Fraud Detection». En: *Scientific Reports* 15.1 (2 de dic. de 2025), pág. 43005. ISSN: 2045-2322. DOI: [10.1038/s41598-025-27010-z](https://doi.org/10.1038/s41598-025-27010-z). URL: <https://www.nature.com/articles/s41598-025-27010-z>.
- [10] Fawaz Khaled Alarfaj y Shabnam Shahzadi. «Enhancing Fraud Detection in Banking With Deep Learning: Graph Neural Networks and Autoencoders for Real-Time

- Credit Card Fraud Prevention». En: *IEEE Access* 13 (2025), págs. 20633-20646. ISSN: 2169-3536. DOI: [10.1109/ACCESS.2024.3466288](https://doi.org/10.1109/ACCESS.2024.3466288). URL: <https://ieeexplore.ieee.org/document/10689393/>.
- [11] Firman Multi. *IEEE-CIS Fraud Detection*. URL: <https://kaggle.com/code/firmanmulti/ieee-cis-fraud-detection>.
- [12] Erik Altman. *IBM Transactions for Anti Money Laundering (AML)*. URL: <https://www.kaggle.com/datasets/ealtman2019/ibm-transactions-for-anti-money-laundering-aml>.
- [13] Imaad Mahmood. *Fraud Guard Synthetic 2025*. URL: <https://www.kaggle.com/datasets/imaadmahmood/fraud-guard-synthetic-2025>.
- [14] Erik Altman y Steve Martinelli. *IBM/AML-Data*. International Business Machines, 23 de feb. de 2026. URL: <https://github.com/IBM/AML-Data>.