

PROYECTO DE TRABAJO DE FIN DE GRADO

Apellidos y nombre del alumno: Frías Hernández, Samuel
DNI: 79.356.066-V

Apellidos y nombre del tutor: Colebrook Santamaría, Marcos
DNI: 43.787.808-V

Título del Proyecto: “Detección de fraude con GNNs frente a métodos tradicionales de Machine Learning”

1. Introducción

La detección automática de fraude en transacciones financieras es un problema clásico de la minería de datos y el aprendizaje automático. En los últimos años, el crecimiento de las redes de pago digitales ha hecho que las relaciones entre entidades (clientes, comercios, tarjetas, etc.) sean cada vez más complejas, lo que motiva el uso de modelos capaces de aprovechar la estructura de grafos subyacente.

Este Trabajo de Fin de Grado tiene como objetivo comparar el rendimiento de **modelos basados en grafos (Graph Neural Networks, GNNs)** con **métodos tradicionales de aprendizaje automático**, como árboles de decisión, máquinas de soporte vectorial o redes densas, en la tarea de detección de fraude.

El proyecto busca no solo evaluar la precisión y eficiencia de ambos enfoques, sino también explorar su interpretabilidad mediante técnicas de **explicabilidad** aplicadas a GNNs.

2. Antecedentes y estado actual del tema

La detección de fraude ha sido ampliamente abordada mediante modelos tradicionales supervisados (por ejemplo, *Random Forest* o *Gradient Boosting*), que se basan en características individuales de las transacciones. Sin embargo, estos modelos no capturan de forma explícita las relaciones entre entidades, lo que limita su capacidad para detectar patrones colectivos de fraude.

Las **Graph Neural Networks (GNNs)** han emergido como una alternativa prometedora al permitir el aprendizaje sobre datos estructurados como grafos, modelando interacciones complejas entre nodos y aristas. Su uso en dominios financieros ha crecido rápidamente, demostrando mejoras en la detección de fraudes, blanqueo de capitales y anomalías transaccionales.

Diversos trabajos recientes, como los de [Cheng et al. \(2024\)](#), [Motie et al. \(2024\)](#), y [Asiri et al. \(2025\)](#), han mostrado que las GNNs pueden superar a los enfoques clásicos en conjuntos de datos con estructura relacional, aunque su interpretabilidad sigue siendo un reto abierto.

3. Actividades a realizar

1. **Revisión bibliográfica:** análisis de trabajos recientes sobre detección de fraude con GNNs y comparación con técnicas tradicionales.
2. **Preparación del conjunto de datos:** selección y preprocesamiento de un dataset público o simulado que represente transacciones financieras.
3. **Implementación de modelos tradicionales:** entrenamiento y evaluación de clasificadores clásicos (árboles, SVM, redes densas).
4. **Implementación de modelos basados en grafos:** diseño, entrenamiento y evaluación de una o varias arquitecturas GNN.
5. **Comparación de resultados:** análisis cuantitativo (precisión, recall, AUC) y cualitativo (complejidad, interpretabilidad)
6. **Módulo de explicabilidad:** aplicación de técnicas para interpretar predicciones del modelo de grafos.

4. Plan de Trabajo

Semanas	Tarea Principal	Hitos
Semanas 1-3	Revisión bibliográfica	→ Búsqueda y análisis de <i>papers</i>. → Definición final de las arquitecturas GNN y modelos tradicionales a comparar. → Borrador inicial del "Estado del arte".
Semanas 4-7	Preparación del conjunto de datos	→ Selección y obtención del <i>dataset</i>. → Limpieza, preprocesamiento e ingeniería de características. → Construcción de la estructura de grafo.
Semanas 8-10	Implementación de modelos tradicionales	→ Implementación de SVM, Random Forest, Redes Densas, etc. → Entrenamiento y ajuste de hiperparámetros. → Evaluación inicial.
Semanas 11-14	Implementación de modelos basados en grafos	→ Diseño e implementación de la arquitectura GNN elegida. → Entrenamiento y ajuste de hiperparámetros. → Evaluación del modelo GNN.

Semanas 15-16	Comparación de resultados	→ Ejecución de la batería final de experimentos. → Generación de métricas. → Creación de tablas y gráficos comparativos.
Semana 17	Módulo de explicabilidad	→ Implementación de técnicas de explicabilidad. → Análisis de las predicciones del modelo GNN. → Interpretación de patrones de fraude detectados.
Semanas 18-19	Redacción final y consolidación	→ Integración de todas las secciones en la memoria final. → Redacción de Conclusiones y Abstract. → Revisión de formato, bibliografía y anexos.
Semana 20	Preparación de la defensa	→ Creación de diapositivas.

5. Propuesta de evaluación

Si se consigue	Calificación
Implementación de modelos tradicionales	5
Implementación de modelos basados en grafos	6 - 7
Comparación de resultados	8 - 9
Módulo de explicabilidad	10

La Laguna, 19 de noviembre de 2025